

# Проверка гипотез о законе распределения

Грауэр Л.В.

# Проверка гипотезы о законе распределения

## Этапы

выдвижение гипотезы о виде закона распределения

оценка параметров распределения

проверка гипотезы

## Критерии согласия

для простых гипотез

для сложных гипотез

# Критерии согласия для простых гипотез

$\xi, X_{[n]}$

$$H_0 : F_{\xi}(x) = F_0(x)$$

$$H_1 : F_{\xi}(x) \neq F_0(x)$$

Критерии согласия, основанные на сравнении

теоретической плотности распределения и гистограммы

теоретической и эмпирической функций распределения

# Критерий $\chi^2$ для простой гипотезы

Разобьем множество значений  $\xi$  на

$$\Delta_1, \Delta_2, \dots, \Delta_r: \quad \Delta_i = (a_{i-1}, a_i], \quad i = 1, \dots, r$$

$$p_i = P\{\xi \in \Delta_i | H_0\}$$

$$n_i = \text{num}\{X_j \in \Delta_i\}$$

# Статистика критерия

$$\chi^2(X_{[n]}) = \sum_{i=1}^r \frac{n}{p_i} \left( \frac{n_i}{n} - p_i \right)^2$$

## Теорема К.Пирсона

Если  $H_0$  верна, тогда

$$\chi^2(X_{[n]}) \xrightarrow[n \rightarrow \infty]{d} \zeta \sim \chi^2(r-1)$$

# Критическая область и p-value

$$\alpha \in (0, 1)$$

$$V_k = \{\chi^2(X_{[n]}) > \chi^2_{1-\alpha}(r-1)\}$$

$$p - value = 1 - F_{\chi^2}(\chi^2(X_{[n]}))$$

## Пример

$i$	0	1	2	3	4	5	$\geq 6$
$n_i$	70	78	34	13	4	1	0

$\xi \sim \text{Pois}(1)$  ?

$n = 200$

$p_0 = 0.368, p_1 = 0.368, p_2 = 0.184, p_3 = 0.061,$   
 $p_4 = 0.015, p_5 = 0.003, p_{\geq 6} = 0.001$

$i$	0	1	2	$\geq 3$
$n_i$	70	78	34	18
$p_i$	0.368	0.368	0.184	0.080
$np_i$	73.6	73.6	36.8	16
$\frac{(n_i - np_i)^2}{np_i}$	0.18	0.26	0.21	0.25



# Критерий Колмогорова для простой гипотезы

Пусть  $F_0(x)$  непрерывна на  $\mathbb{R}$ .

Статистика Колмогорова:

$$D_n(X_{[n]}) = \sup_{x \in R} |F_n^*(x) - F_0(x)|.$$

Если верна  $H_0$ , то

$$D_n(X_{[n]}) \xrightarrow[n \rightarrow \infty]{\text{п.н.}} 0$$

Если верна  $H_1$ , то

$$D_n(X_{[n]}) \xrightarrow[n \rightarrow \infty]{\text{п.н.}} \sup_{x \in R} |G(x) - F_0(x)| > 0.$$


# Теорема Колмогорова

## Теорема А.Н. Колмогорова

Если гипотеза  $H_0$  верна, и  $F_0(x)$  — непрерывная функция на  $\mathbb{R}$ , тогда имеет место сходимость:

$$P\{\sqrt{n}D_n(X_{[n]}) < z\} \xrightarrow{n \rightarrow \infty} K(z) = 1 + 2 \sum_{m=1}^{\infty} (-1)^m e^{-2m^2 z^2}.$$

$$V_k = \{\sqrt{n}D_n(X_{[n]}) > d_{1-\alpha}\}$$



## Пример

$X_{[n]}$ : 0.25, 1.48, 0.32, 0.17, 1.66, 0.29, 0.02, 1.31, 0.12, 3.09

$\xi \sim E(1)$  ?

$X_{(i)}$	0.02	0.12	0.17	0.25	0.29	0.32	1.31	1.48	1.66	3.09
$F_0(x_{(i)})$	0.02	0.11	0.16	0.22	0.25	0.27	0.73	0.77	0.81	0.95
$F^*(x_{(i)})$	0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9

$$D_{10} = \quad \quad \sqrt{10}D_{10} =$$

$$\alpha = 0.05, \quad d_{1-\alpha} = 1.36$$

# Критерии согласия для сложных гипотез

$\xi, X_{[n]}$

$$H_0 : F_\xi \in \{F(\cdot/\theta) : \theta \in \Theta \subset \mathbb{R}^I\}$$

$$H_1 : F_\xi \notin \{F(\cdot/\theta) : \theta \in \Theta \subset \mathbb{R}^I\}$$

# Критерий $\chi^2$ для сложных гипотез

Разобьем множество значений  $\xi$  на

$$\Delta_1, \Delta_2, \dots, \Delta_k: \quad \Delta_i = (a_{i-1}, a_i], \quad i = 1, \dots, k$$

$$p_i(\theta) = P\{\xi \in \Delta_i | H_0\}$$

$$n_i = \text{num}\{X_j \in \Delta_i\}$$

# Теорема Фишера

Пусть  $\Theta$  – открытое множество в  $\mathbb{R}^l$ .

Пусть выполнены условия:

1. Для любого  $\theta \in \Theta$ :  $\sum_{i=1}^k p_i(\theta) = 1$ .
2. Для любого  $\theta \in \Theta$ :  $p_i(\theta) > c > 0$  для любого  $i = \overline{1, k}$ .
3. Для любого  $\theta \in \Theta$  существуют и непрерывны производные:  
 $\partial p_i(\theta) / \partial \theta_j$ ,  $\partial^2 p_i(\theta) / (\partial \theta_u \partial \theta_v)$  для любого  $i = 1, \dots, k$ ,  
 $u, v, j = 1, \dots, l$ .
4. Для любого  $\theta \in \Theta$  матрица  $\left( \frac{\partial p_i(\theta)}{\partial \theta_j} \right)_{i,j=\overline{1,k}}$  имеет ранг  $l$ .

Пусть  $\hat{\theta} = \arg \max_{\theta \in \Theta} L(\{n_i\}, \theta)$ , где

$$L(\{n_i\}, \theta) = \frac{n!}{n_1! \cdot \dots \cdot n_k!} \prod_{i=1}^k p_i^{n_i}(\theta),$$

или  $\hat{\theta}$  — оценка по методу минимума хи-квадрат:

$$\hat{\theta} = \arg \min_{\theta \in \Theta} \sum_{i=1}^k \frac{(n_i - np_i(\theta))^2}{np_i(\theta)}.$$

Тогда, если гипотеза  $H_0$  верна, то

$$\chi^2(\hat{\theta}) = \sum_{i=1}^k \frac{(n_i - np_i(\hat{\theta}))^2}{np_i(\hat{\theta})} \xrightarrow[n \rightarrow \infty]{d} \zeta \sim \chi_{k-l-1}^2.$$



## Критическая область и p-value










$$\chi^2(\hat{\theta}) = \sum_{i=1}^k \frac{(n_i - np_i(\hat{\theta}))^2}{np_i(\hat{\theta})}$$

$$\alpha \in (0, 1)$$

$$V_k = \{\chi^2(\hat{\theta}) > \chi_{1-\alpha}^2(k - l - 1)\}$$

$$p - value = 1 - F_{\chi^2}(\chi^2(\hat{\theta}))$$

# Критерий Колмогорова для сложных гипотез?



## Оценки вероятности ошибки 1го рода

Гипотеза	$E(0.5)$	$N(5, 2)$	$U(1, 5)$
Простая	0.048	0.044	0.048
Сложная	0.004	0.000	0.045

## Оценки мощности

Гипотеза	$0.75E + 0.25U$	$0.75N + 0.25U$	$0.75U + 0.25N$
Простая	0.596	0.083	0.521
Сложная	0.028	0.001	0.492

Возможный вариант:  
разбить выборку на 2 части:

построить оценки по 1й части

проверить гипотезу по 2й части